IFT 359 Programmation fonctionnelle

Travail pratique 2

Listes et fonctions d'ordre supérieur

Composition des équipes:

- Par équipe
- Une seule réponse sera fournie par équipe.

Barème de correction

Ce travail pratique est noté sur 7 points (7% de la note finale) :

- 3 points : Réussite des jeux d'exécution
- 2.5 points : Utilisation de fonctions de haut niveau qui manipulent des séquences ou des fonctions
  - Exemple de telles fonctions : `apply`, `map`, `filter`, `filter-not`, `takef`, `flatten`, `foldr`, `foldl`, `filter-map`, `append-map`, `ormap`, `andmap`, `argmin`, `argmax`, `group-by`...
  - 0.5 pt par fonction différente utilisée.
  - 0.5 : élégance des solutions. Par exemple, la solution évite de parcourir plusieurs fois la même liste en utilisant de façon judicieuse le bon opérateur (utiliser foldr pour construire la solution en accumulant les états intermédiaires dans un dictionnaire.
- 1.5 points : Évaluation du code
  - Définition, utilisation et respect de barrières d'abstraction. (+)
  - Définition de fonctions qui rendent des fonctions. (+)
  - Définitions de fonctions utilitaires. (+)
  - Tous les cas de figure sont traités. (+)
  - Clarté du code. (+)
  - Les solutions qui n'utilisent aucune fonction de haut niveau. (-)
  - Code incomplet ou incorrect. (-)
  - Un prédicat rend explicitement #f ou #t. (-)
  - Code inutilement complexe. (-)

Tout retard entraînera la note de zéro.

Remise

Vous devez remettre les fichiers suivants

Nom du fichier	En-tête Votre fichier doit commencer par les lignes suivantes

IFT359-tp2-MapReduce.rkt	`#lang racket`
	`(provide périodes*)`
	`(provide total-clics)`
	`(provide total-clics-sujet)`
	`(provide sujets*)`
	`(provide sujets-liés)`
	`(provide populaires)`
	`(provide top)`
	`(provide hot)`
	`(provide consultation)`

Chaque fichier doit avoir comme en-tête :

```
; ***************** IFT359 / TP2
; ***************** Nom, prénom et matricule du 1er membre de l'équipe
; ***************** Nom, prénom et matricule du 2e membre de l'équipe
```

Votre code ne doit comprendre que les définitions sans aucun appel de fonction pour produire les résultats. Il ne doit pas y avoir non plus d'instructions d'entrée / sortie. Vous pouvez le faire en n'écrivant aucune expression autre que la définition de fonctions ou en mettant vos jeux d'essais en commentaires.

Énoncé

La librairie MapReduce définie par Google s'appuie sur les propriétés de la programmation fonctionnelle afin de répartir sur des milliers d'ordinateurs des calculs qui impliquent des térabytes de données. MapReduce s'appuie sur la programmation fonctionnelle, en particulier l'absence d'effets de bord et les fonctions qui manipulent des fonctions et des séquences.

Pour ce TP, nous allons explorer une version simplifiée des problèmes qui peuvent être aisément résolus avec la librairie MapReduce. Les requêtes de recherche transmises au moteur de recherche de Google sont traitées par un ensemble de serveurs. Chaque serveur maintient un journal (log) de ces requêtes et des clics des usagers sur les URLs proposées dans la liste des résultats de la recherche. Chaque entrée du journal d'un serveur spécifie l'URL, la date, le sujet de la page[1] et l'émotion que véhicule cette page. Comme un URL peut traiter de plusieurs sujets, un même URL peut avoir été cliqué pour des recherches différentes et peut donc apparaitre plusieurs fois dans le journal avec des sujets différents lui étant associés.

L'objectif est d'extraire des journaux des informations s'apparentant à celles obtenues par Google Analytics. Google Analytics est un outil puissant qui permet de suivre et d'analyser le comportement des utilisateurs sur un site web ou une application. Vous devez écrire les fonctions qui vont recueillir des statistiques à la manière de Google Analytics ou encore qui vont aider à détecter des tendances ou des polarisations extrêmes ou prédire les épidémies[2].

Soit les fonctions suivantes qui permettent de construire un journal du moteur de recherche de Google.

; structure d'une entrée de journal

```
; constructeur
(define (entrée-journal url date sujets émotion)
  (list url date sujets émotion))
; accesseurs
(define (url entrée-journal) (car entrée-journal))
(define (date entrée-journal) (cadr entrée-journal))
(define (sujets entrée-journal) (caddr entrée-journal))
(define (émotion entrée-journal) (cadddr entrée-journal))
```

Voir fichier « `TP2-Journal.rkt` ».

Pour simplifier le traitement,

- La date sera un entier qui correspondra au numéro du jour.
- Les valeurs possibles de l'attribut « émotion » sont {`positif`, `négatif`, `neutre`}.

---

[1] Plus précisément, les mots-clés du sujet de la recherche.

[2] Lu, F.S., Hattab, M.W., Clemente, C. *et al.* Improved state-level influenza nowcasting in the United States leveraging Internet-based data and network approaches. *Nat Commun***10**, 147 (2019). https://doi.org/10.1038/s41467-018-08082-0

Implémenter les fonctions du tableau ci-dessous

Signature	Résultat	Description
`(périodes* journaux)`	Liste de triplets `(journal, date-min, date-max)`	Extraire pour chaque journal la date de début la plus petite et la plus grande.
`(total-clics journaux début fin)`	Nombre entier	Calculer le nombre total de clics sur l'ensemble des URL pour l'ensemble des journaux entre la date du début incluse et la date de fin incluse. Une entrée du journal correspond à un clic.
`(total-clics-sujet journaux sujet début fin)`	Nombre entier	Calculer le nombre de clics sur un sujet pour l'ensemble des journaux entre la date du début incluse et la date de fin incluse.
`(sujets* journaux)`	Liste de tous les sujets sans répétition.	Extraire l'ensemble de tous les sujets qui apparaissent dans les journaux.
`(sujets-liés journaux URL début fin)`	Liste de tous les sujets sans répétition.	Extraire la liste de tous les sujets associés à une page qui ont mené à un clic pour l'ensemble des journaux entre la date du début incluse et la date de fin incluse.
`(populaires journaux seuil début fin)`	Liste de tous les URLs sans répétition qui respectent la condition.	Extraire l'ensemble des URL qui ont dépassé ou égalé un certain seuil de clics dans les journaux entre la date du début incluse et la date de fin incluse.
`(top journaux n seuil début fin)`	Liste des `n` URLs sans répétition. Il se peut qu'il y ait moins de `n` URL qui satisfassent la contrainte.	La liste en ordre décroissant de clics des `n` URL qui ont dépassé ou égalé un certain seuil de total de clics dans l'ensemble des journaux indépendamment du sujet de recherche entre la date du début incluse et la date de fin incluse.
`(hot journaux n nbjours début fin)`	Liste des paires `(sujet . nb-consécutifs)`	Sujet hot = dans le top n pendant au moins `nbjours` consécutifs pour une période donnée
`(consultation journaux sujets émotion début fin)`	Liste de toutes des paires `(url . nbclics)`	Extraire l'ensemble des paires (url . nbclics) pour les URL qui traitent d'un des sujets de la liste avec l'émotion spécifiée entre la date du début incluse et la date de fin incluse.

Exemples de comportements attendus

Voir les fichiers `"TP2-exemple-journaux.rkt"` et `"TP2-exemples-MapReduce.rkt"`.